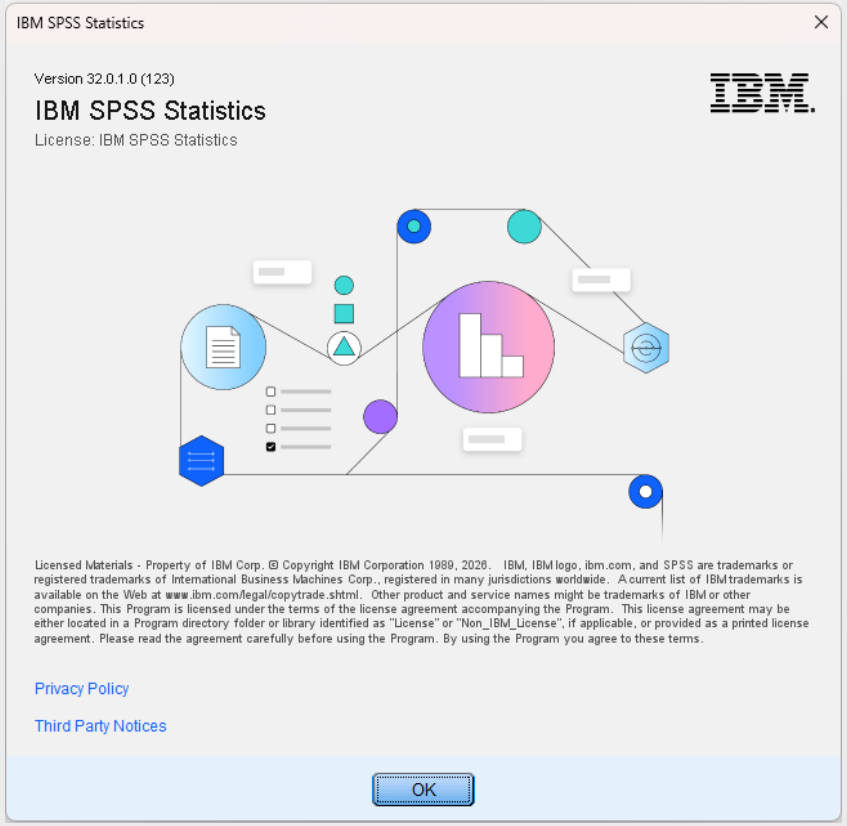
IBM SPSS Statistics 32.0.1



מני ברגר

מדען נתונים, ג'יניוס מערכות

אוקטובר 2026

- Meni@genius.co.il
- Professional Facebook community: SPSS Israel
- https://github.com/Dataninjapro



מנתונים להחלטות - בלי ללכת לאיבוד ביער

מעץ החלטה למודל מעשי ב- ***SPSS***

מה מחכה לנו ביער?

- נבנה יחד עץ החלטה מסוג CHAID ב- IBM SPSS Statistics 32.0.1
- נגלה קבוצות סיכון וקשרים שהממוצע עלול להסתיר
- נלמד לקרוא את הענפים ולהפוך אותם לכללי החלטה ברורים
- נבדוק אם העץ באמת מצליח לזהות את אוכלוסיית המטרה
- נראה כיצד מעבירים את המודל מהפלט אל מקרים חדשים באמצעות Scoring

מנתונים גולמיים לתובנה מוסברת ולמודל שאפשר להפעיל.

הבעיה ומטרת המודל

זיהוי נשירה כאשר אפשר להתערב

- ***שאלת המחקר***

בתום הסמסטר הראשון, האם ניתן לזהות סטודנטים בסיכון לנשירה ולהבין מה מאפיין את קבוצות הסיכון?

- ***מטרות המחקר***

לחזות • לזהות קבוצות סיכון • להפיק כללי החלטה מוסברים

המודל מיועד לתיעדוף תמיכה מוקדמת ולא לקבלת החלטות אוטומטית נגד סטודנטים.

קובץ הנתונים

הנתונים שעמדו לרשותנו בתום הסמסטר הראשון

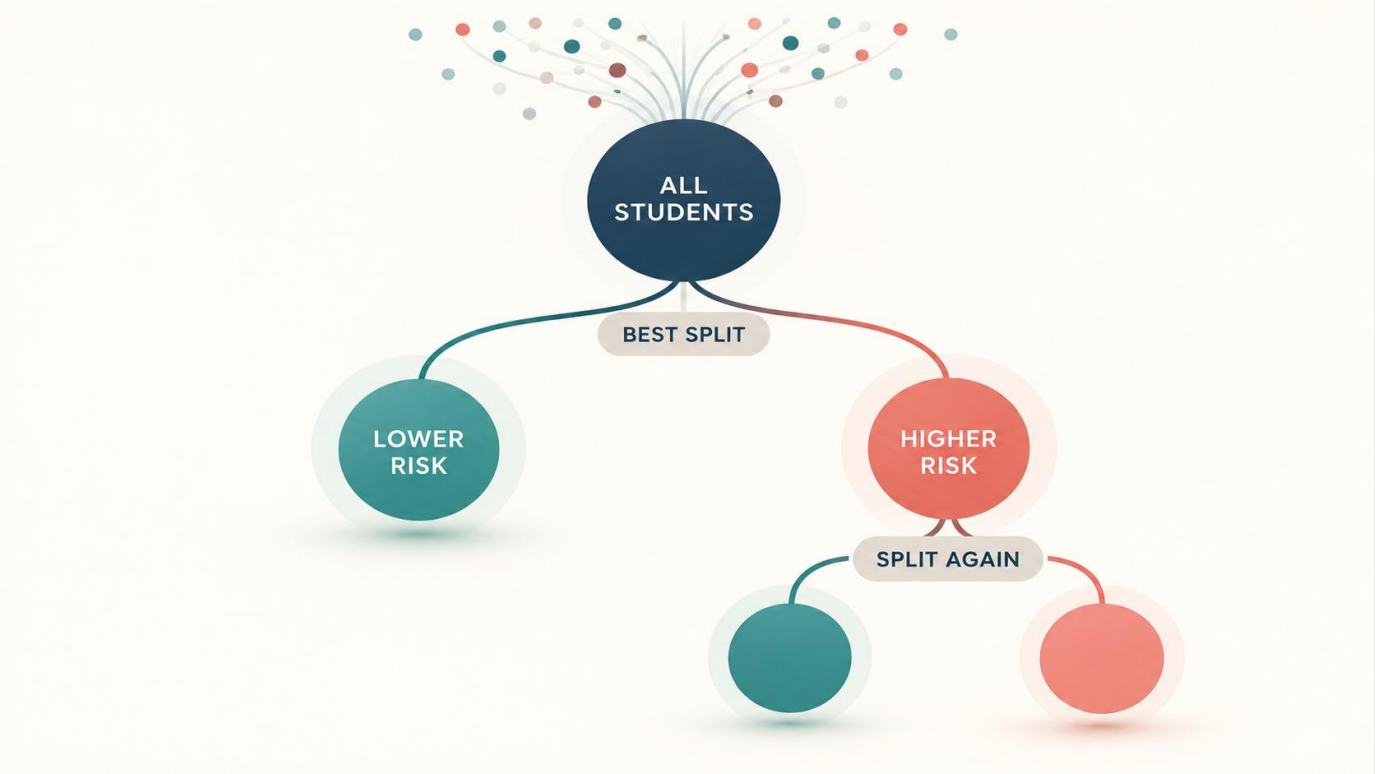
- **3,630 סטודנטים** בעלי תוצאה סופית.
- **Target:** 1,421 Dropout מול 2,209 Graduate.
- **14 Candidate Predictors** שהיו זמינים עד תום הסמסטר הראשון.
- נתוני הסמסטר השני הושמטו כדי למנוע **Data leakage**.
- סטודנטים שעדיין Enrolled הוצאו, משום שהתוצאה שלהם טרם הוכרעה.

Data source: Realinho, V., Vieira Martins, M., Machado, J., & Baptista, L. (2021). Predict Students' Dropout and Academic Success [Dataset]. UCI Machine Learning Repository. https://doi.org/10.24432/C5MC89
Demo preparation: Enrolled cases excluded; target recoded as Dropout vs. Graduate; second-semester predictors omitted.

איך CHAID מתפצל?

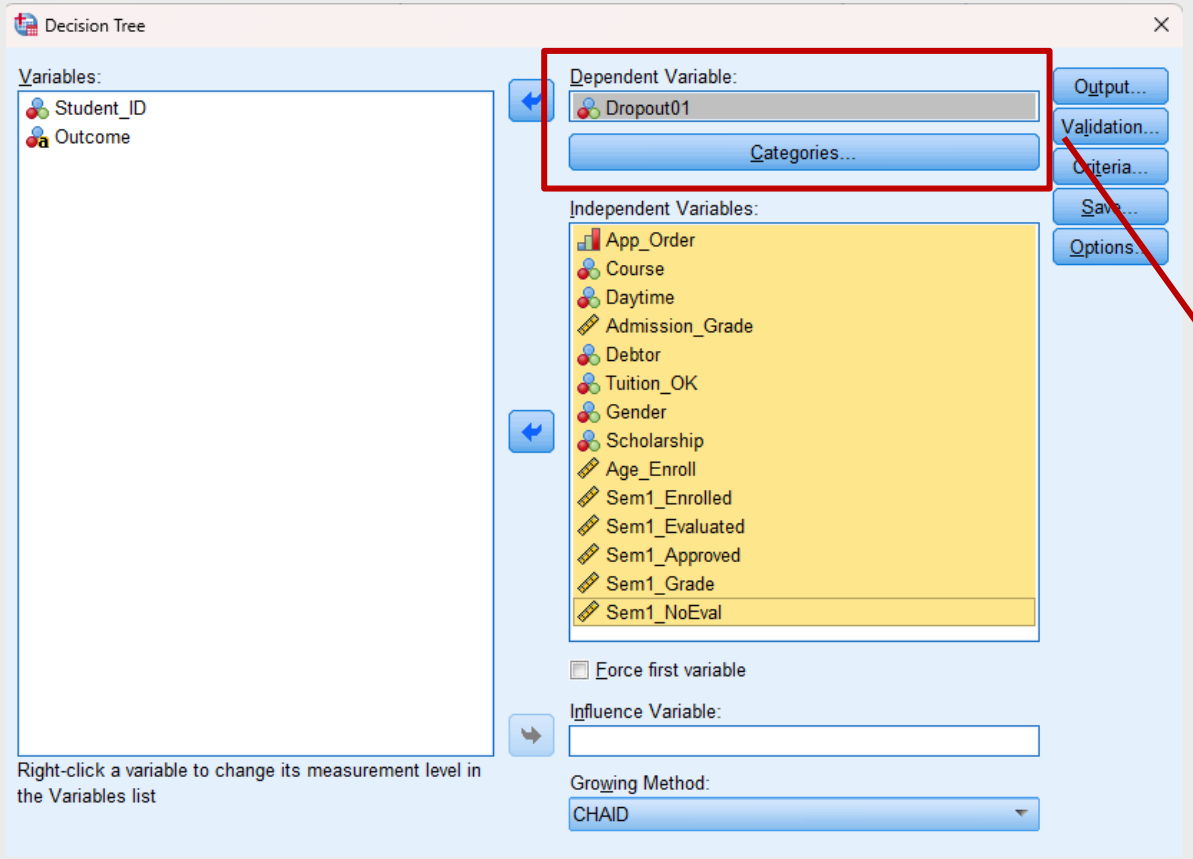
CHAID - Chi-squared Automatic Interaction Detection

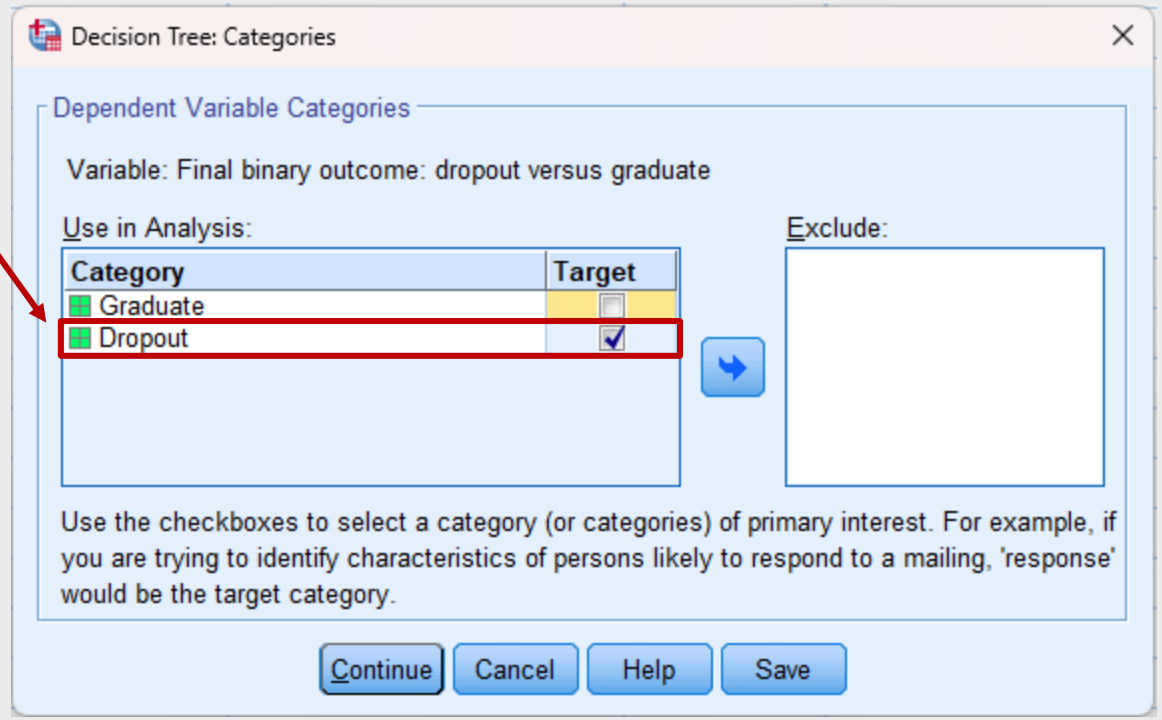
משתמש במבחני חי-בריבוע כדי לקבץ ערכים דומים ולבחור את המשתנה שיוצר את ההפרדה המובהקת ביותר במשתנה התוצאה. לאחר הפיצול הוא חוזר על התהליך בכל ענף.



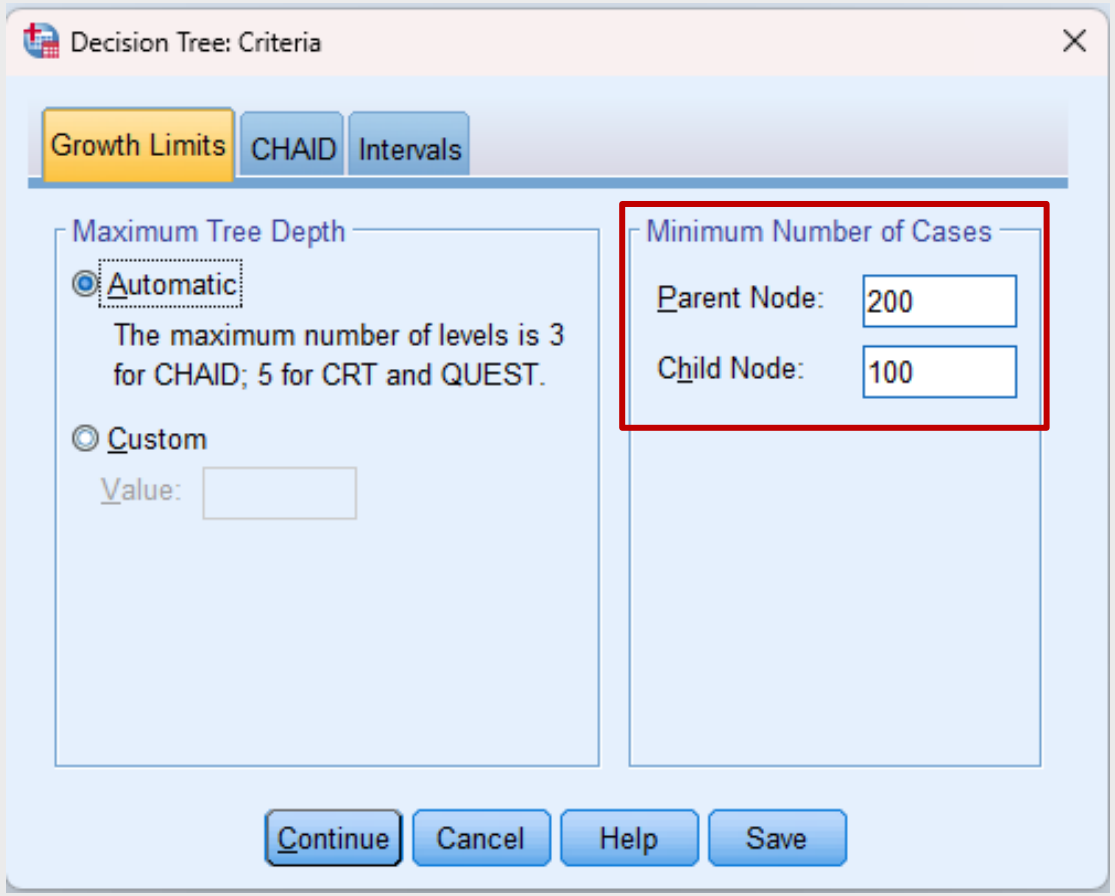
הגדרת המודל

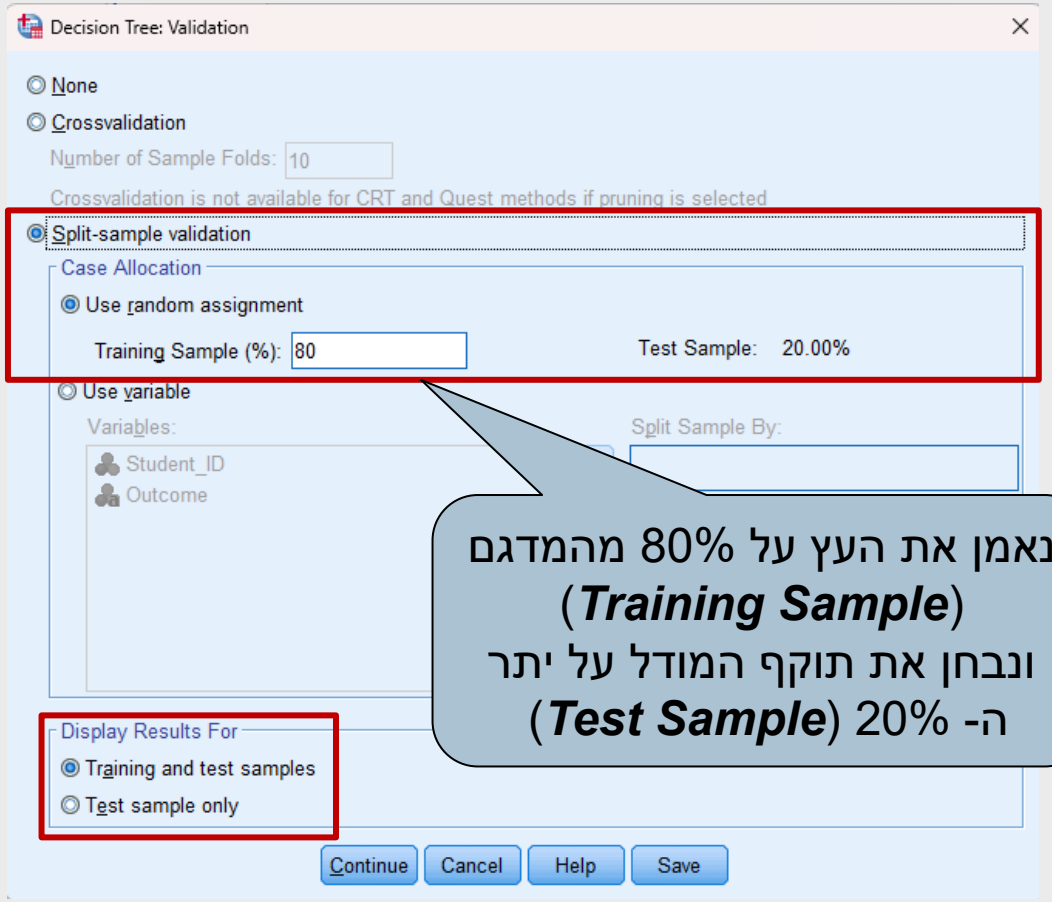
Analyze >> Classify >> Tree





הגדרת המודל





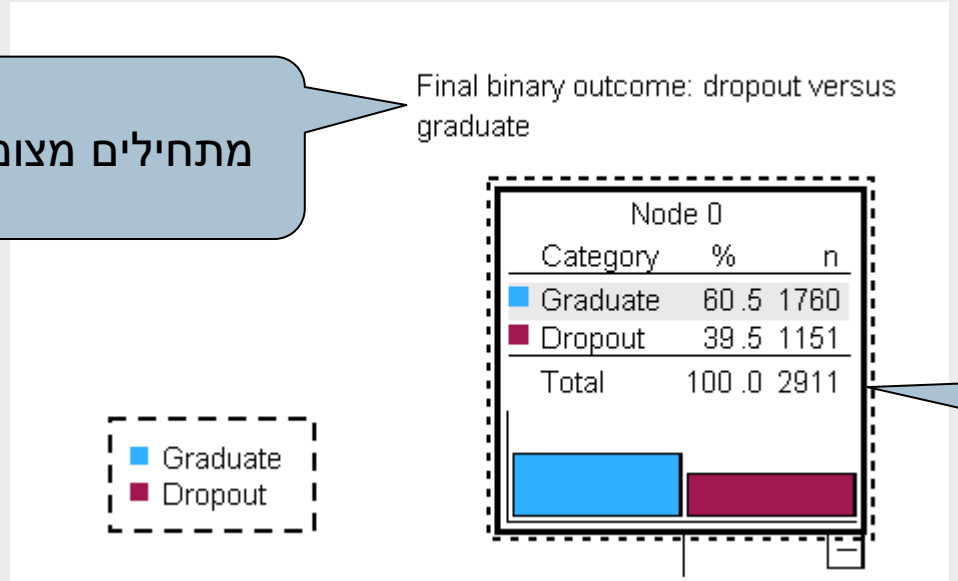
נאמן את העץ על 80% מהמדגם (***Training Sample***)
ונבחן את תוקף המודל על יתר ה- 20% (***Test Sample***)

מתחילים בשורש

נשים לב! מתוך 14 משתנים מועמדים, העץ השתמש ב- 4 משתנים בלבד!

נתחיל מלמעלה ונעקוב אחרי "ענף" אחד←

מתחילים מצומת השורש

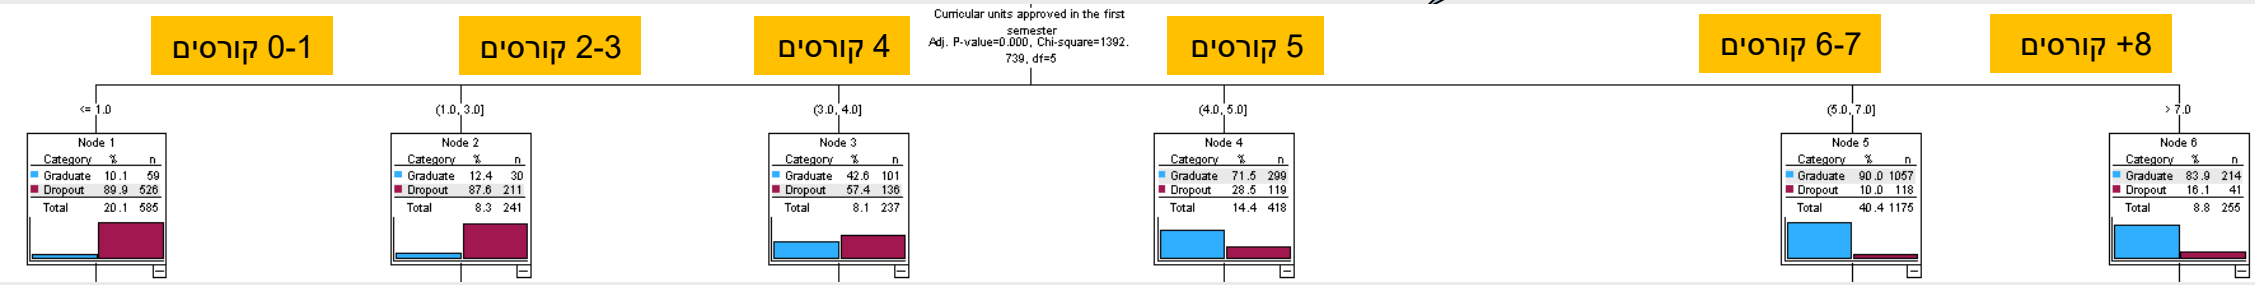


העץ נבנה על מדגם האימון (Train),
הכולל 2,911 סטודנטים.
לפני כל פיצול בעץ,
שיעור הנשירה הוא 39.5%,
ולכן ברמת הבסיס הקטגוריה
השכיחה היא Graduate.

הפיצול ראשון

המשתנה שהצליח ליצור את ההפרדה החזקה ביותר הוא: מספר הקורסים שהסטודנט עבר בסמסטר הראשון.

ניכרת מגמה ברורה:
ככל שהסטודנט עבר יותר קורסים כך אחוז הנוטשים בכל צומת הולך ופוחת



CHAID לא הסתפק בבחירת מספר הקורסים שעברו. הוא גם קיבץ את הערכים לשישה טווחים שבהם שיעורי הנשירה דומים בתוך הקבוצה ושונים בין הקבוצות.

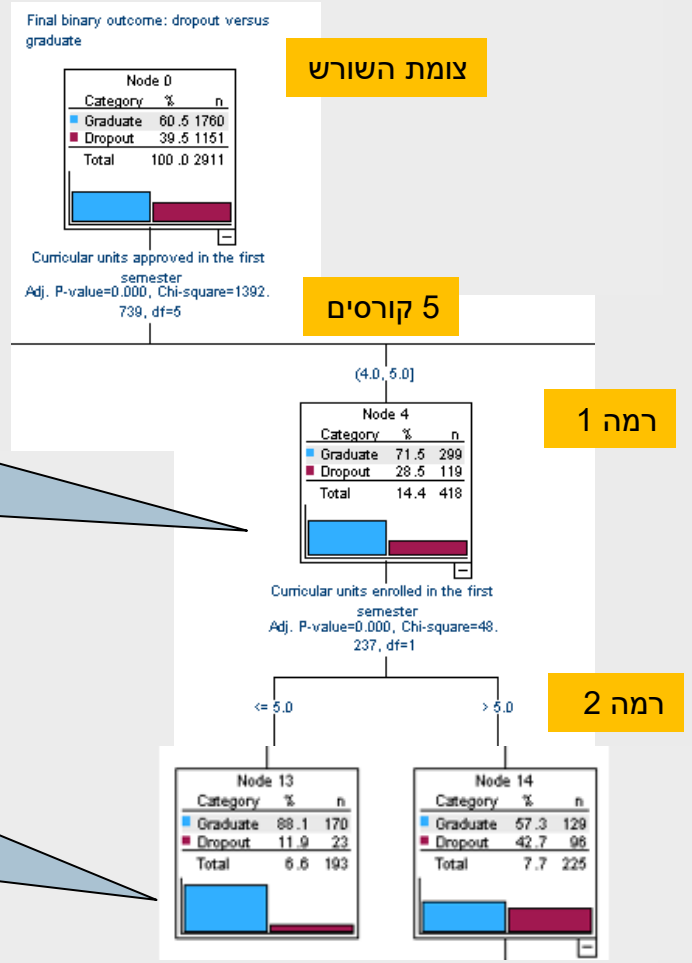
האינטראקציה בענף



לא מספיק לדעת כמה קורסים הסטודנט עבר. חשוב לדעת גם לכמה קורסים נרשם!
חמישה מתוך חמישה אינם שקולים לחמישה מתוך מספר גדול יותר.

בקרב 418 סטודנטים שעברו חמישה קורסים, שיעור הנשירה הוא 28.5%. אבל הנתון הזה עדיין מסתיר שתי קבוצות שונות מאוד.

לאחר הפיצול לפי מספר קורסים שנרשם בסמסט' א':
נרשמו לעד חמישה קורסים: **11.9% נשירה**.
נרשמו ליותר מחמישה קורסים: **42.7% נשירה**.



איפה הדובים? מוקדי הסיכון

נבחן כעת את הישגי (Gains) מדגם האימון ונתמקד בצומת 7.

מרכז כ- 16.1% מהמדגם.

מרכז 40.6% מכלל מקרי הנשירה במדגם האימון, אף שהוא כולל רק 16.1% מהסטודנטים.

כמעט כל הסטודנטים בצומת 7 נשרו : 467 מתוך 469.

שיעור הנשירה גבוה פי 2.52 משיעור הנשירה הכללי.

Gains for Nodes

Sample	Node	Node N	Node Percent	Gain N	Gain Percent	Response	Index
Training	7	469	16.1%	467	40.6%	99.6%	251.8%
	10	115	4.0%	111	9.6%	96.5%	244.1%
	11	113	3.9%	91	7.9%	[illegible]	203.7%
	9	126	4.3%	[illegible]	[illegible]	79.4%	200.7%
	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible].8%	153.8%
	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible].9%	128.6%
	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible].3%	91.8%
	[illegible]	[illegible]	[illegible]	[illegible]	[illegible]	[illegible].9%	68.0%
	16	167	5.7%	37	3.2%	22.2%	56.0%
	19	100	3.4%	20	1.7%	20.0%	50.6%
	22	189	6.5%	31	2.7%	16.4%	41.5%
	13	193	6.6%	23	2.0%	11.9%	30.1%
	17	136	4.7%	9	0.8%	6.6%	16.7%
	21	819	28.1%	50	4.3%	6.1%	15.4%

מדד ה- Index מסייע לתעדף צמתים בסיכון חריג, לצד גודל הצומת וה- Gain.

האם המצפן עובד?

Risk הוא שיעור המקרים שהעץ מסווג לקטגוריה הלא נכונה: ככל שהערך נמוך יותר, המודל מדויק יותר.

Risk

Sample	Estimate	Std. Error
Training	.140	.006
Test	.185	.014

Growing Method: CHAID

מדגם ה- training מפגין 14.0% סיווגים שגויים

מדגם ה- testing מפגין 18.5% סיווגים שגויים

מתוך 1151 נושרים במדגם האימון, העץ זיהה נכון 904 והחמיץ 247.

Classification

Sample	Observed	Predicted: Graduate	Predicted: Dropout	Percent Correct
Training	Graduate	1600	160	90.9%
	Dropout	247	904	78.5%
	Overall Percentage	63.4%	36.6%	86.0%

קטג' Graduate 90.9% סווגו נכון

קטג' Dropout 78.5% סווגו נכון

סה"כ הסיווגים הנכונים במדגם האימון – 86.0%!

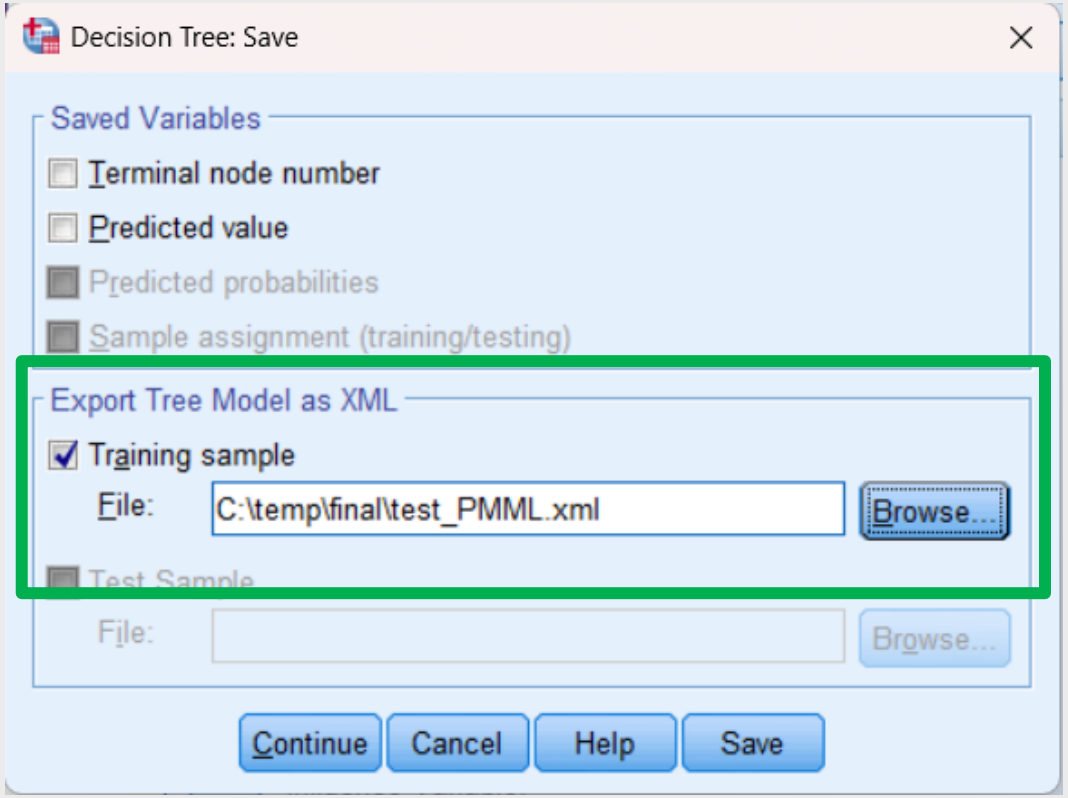
העץ מגיע לשולחן של סיגל

מאות סטודנטים. מעט שעות ייעוץ.
היכן מתחילים?

המודל אינו מחליט במקום סיגל.
הוא מסייע לה למקד את תשומת הלב והמשאבים העומדים לרשותה.



Let's score!



אז כיצד הופכים עץ שנמצא בפלט למערכת חוקים שאפשר להפעיל אוטומטית על קובץ חדש?

נשמור את המודל כקובץ- XML בפורמט PMML, ונשתמש בו כדי לבצע Scoring לסטודנטים החדשים, בלי לבנות את העץ מחדש!

סט הדגמה מכוון

המשתנים שהשתלבו בעץ ← 1 2 3 4

Demo_ID	Age_Enroll	Course	Sem1_Approved	Sem1_Enrolled
Student_01	19	9773	0	6
Student_05	19	9853	5	6
Student_14	19	9500	6	7
Student_02	29	9003	3	6
Student_03	18	9254	4	6
Student_04	29	9670	3	5
Student_06	19	171	0	0
Student_07	19	9085	4	5
Student_08	34	9147	12	15
Student_09	28	9254	6	6
Student_10	19	9238	5	6
Student_11	19	9773	6	6
Student_12	20	9147	5	5
Student_13	22	171	12	12

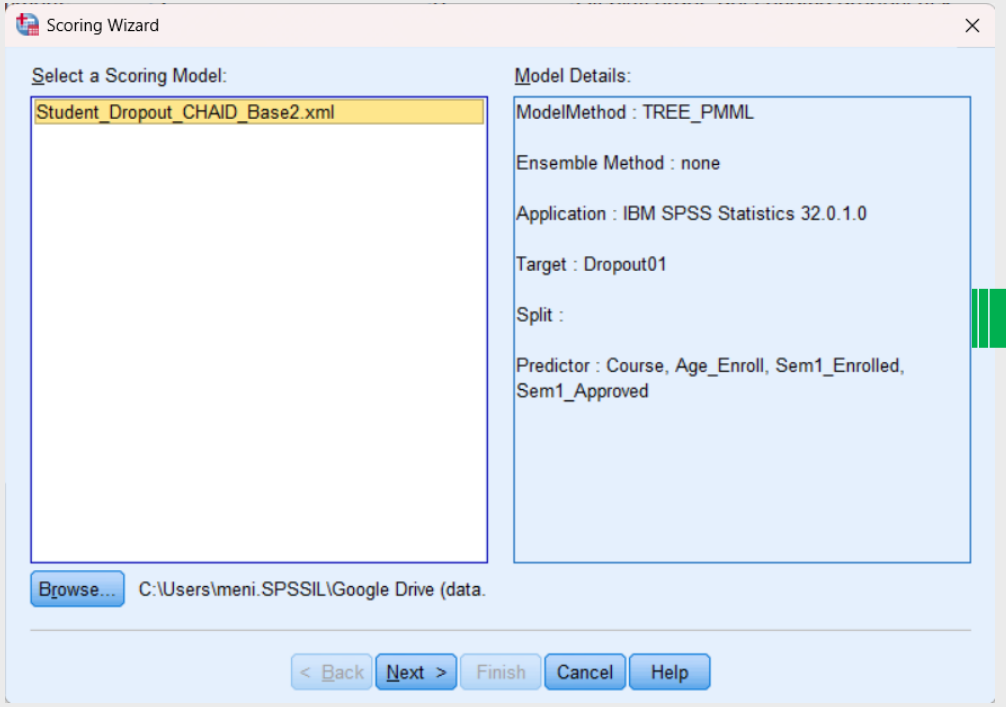
לצורך ההדגמה נבחרו 14 מקרים.
מקרה אחד מכל צומת סופי בעץ,
כדי לייצג את כל מסלולי ההחלטה
ולהראות כיצד פרופילים שונים
מקבלים Scoring.

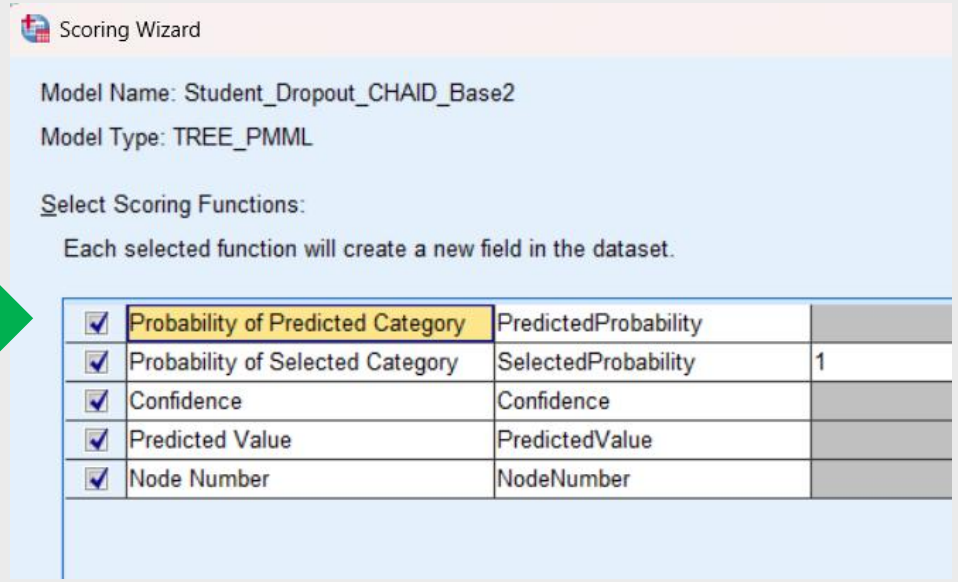
זהו אינו מדגם תיקוף נוסף!

- מדגם ה- test: האם המודל עובד?
- 14 המקרים: כיצד מערכת החוקים מתפקדת בפועל.

הפעלת מנגנון ה- Scoring

Utilities >> Scoring Wizard





בחינת הסיווג החזוי בסט ההדגמה

מזהה סטודנט	תוצאה חזויה	הסתברות לתוצאה החזויה
Student_01	Dropout	1.00
Student_05	Dropout	.61
Student_14	Graduate	.94

מה לקחת מהיער?

- CHAID הופך אוכלוסייה הטרוגנית לקבוצות סיכון שקל להבין.
- קריאת הענפים והמדדים מאפשרת לזהות היכן כדאי למקד התערבות.
- העץ הופך מתוצר אנליטי סטטי למערכת חוקים תפעולית שניתן להפעיל על מקרים חדשים.

לסיכום ערכו של עץ החלטה אינו בחיזוי מי נמצא בסיכון, אלא בהבנת הסיכון ובהפיכתו לפעולה עקבית.